

# **Statistische Modellierung III**

## **-Das allgemeine lineare Modell-**

Dr. Martin Scharpenberg

MSc Medical Biometry/Biostatistics

WiSe 2019/2020

## Das allgemeine lineare Modell

## Allgemeines lin. Modell - Setup

- Betrachten wieder Beobachtungen  $(Y_i, \mathbf{x}_i)$ ,  $i = 1, \dots, n$ , wobei  $\mathbf{x}_i \in \mathbb{R}^k$  fixe Kovariablen und die Zielvariablen  $Y_i$  wieder Zufallsvariablen sind.
- Betrachten das Modell  $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$ , wobei  $\varepsilon$  ein Zufallsvektor der Dimension  $n$  mit  $E(\varepsilon) = 0$  und  $\text{Cov}(\varepsilon) = \sigma^2 \mathbf{W}$ . Dabei ist  $\sigma^2 > 0$  und  $\mathbf{W}$  eine symmetrische, positiv-definite Matrix.
- Es muss nun also weder Unabhängigkeit noch Varianzhomogenität gelten!
- Nehmen Normalverteilung an, d.h.  $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{W})$  und  $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{W})$ .
- Nehme zudem an, dass  $\text{Rang}(\mathbf{X}) = k$ .

## Beispiel: Gruppierte Daten

- $m$  Gruppen  $G_1, \dots, G_m$  mit  $\mathbf{x}_i = \mathbf{x}_j = \mathbf{z}_l \in \mathbb{R}^k$  für alle  $i, j$  in Gruppe  $G_l$
- z.B. wenn alle Kovariablen kategorial sind (Geschlecht, Krankheitsstadium, etc.)
- Daten können durch die Mittelwerte der  $Y_i$  einer Gruppe  $G_l$  zusammengefasst werden, d.h. durch

$$\bar{Y}_l = \frac{1}{n_l} \sum_{i \in G_l} Y_i, \quad \text{wobei } n_l = |G_l|.$$

- Erhalten Daten der Form  $(\bar{Y}_l, \mathbf{z}_l)$ ,  $l = 1, \dots, m$ , die stochastisch unabhängig sind.
- Wenn  $Y_i \sim N(\mathbf{z}_l \beta, \sigma^2)$  für alle  $i \in G_l$ , dann  $\bar{Y}_l \sim N(\mathbf{z}_l \beta, \frac{\sigma^2}{n_l})$ ,  $l = 1, \dots, m$
- Also:  $\bar{\mathbf{Y}} \sim N(\mathbf{Z} \beta, \sigma^2 \mathbf{W})$  mit  $\mathbf{W} = \text{diag}(1/n_1, \dots, 1/n_m)$

## Verhalten des klassischen KQ-Schätzers

- Betrachten den klassischen KQ-Schätzer  $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$
- $\hat{\beta}$  ist immernoch erwartungstreu, d.h. es gilt  $E(\hat{\beta}) = \beta$
- Für die Kovarianz gilt jetzt:

$$\text{Cov}(\hat{\beta}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W} \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1}$$

- Dies entspricht nicht mehr der Kovarianz aus dem klassischen linearen Modell. Die klassischen Test und Konfidenzintervalle würden also falsche Ergebnisse liefern.
- Werden sehen, dass  $\hat{\beta}$  nun nicht mehr BLUE ist.

## Der Aitken-Schätzer

- Betrachten nun transformierte Daten

$$\mathbf{Y}^* = \mathbf{W}^{-1/2}\mathbf{Y}, \quad \mathbf{X}^* = \mathbf{W}^{-1/2}\mathbf{X}, \quad \text{und } \boldsymbol{\varepsilon}^* = \mathbf{W}^{-1/2}\boldsymbol{\varepsilon},$$

wobei  $\mathbf{W}^{-1/2}$  eine Wurzel von  $\mathbf{W}^{-1}$  ist (vgl. Vektor- und Matrixrechnung)

- Nun gilt

$$\mathbf{Y}^* = \mathbf{X}^*\boldsymbol{\beta} + \boldsymbol{\varepsilon}^*,$$

mit  $E(\boldsymbol{\varepsilon}^*) = 0$  und  $\text{Cov}(\boldsymbol{\varepsilon}^*) = \sigma^2\mathbf{I}$ , d.h.  $(Y_i^*, \mathbf{x}_i^*)$  erfüllen wieder die Voraussetzungen des klassischen Gauß-Markov-Modells.

Dies führt zum allgemeinen KQ-Schätzer

$$\hat{\boldsymbol{\beta}}^{\mathbf{W}} = (\mathbf{X}^{*T}\mathbf{X}^*)^{-1}\mathbf{X}^{*T}\mathbf{Y}^* = (\mathbf{X}^T\mathbf{W}^{-1}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{W}^{-1}\mathbf{Y}$$

der auch *Aitken-Schätzer* genannt wird.

## Eigenschaften des Aitken-Schätzers

- Man kann zeigen, dass

$$\hat{\beta}^{\mathbf{W}} = \operatorname{argmin}_{\tilde{\beta} \in \mathbb{R}^k} (\mathbf{Y} - \mathbf{X}\tilde{\beta})^T \mathbf{W}^{-1} (\mathbf{Y} - \mathbf{X}\tilde{\beta})$$

- Im Falle einer Diagonalmatrix  $\mathbf{W} = \operatorname{diag}(w_1, \dots, w_n)$  ist

$$(\mathbf{Y} - \mathbf{X}\tilde{\beta})^T \mathbf{W}^{-1} (\mathbf{Y} - \mathbf{X}\tilde{\beta}) = \sum_{i=1}^n (Y_i - \mathbf{x}_i \tilde{\beta})^2 / w_i$$

die gewichtete Quadratsumme mit Gewichten  $1/w_i$

- In diesem Fall wird der Aitken-Schätzer auch häufig *gewichteter KQ-Schätzer* genannt

## Eigenschaften des Aitken-Schätzers

Unter den Modell-Annahmen  $E(\mathbf{Y}) = \mathbf{X}\beta$  und  $\text{Cov}(\mathbf{Y}) = \sigma^2\mathbf{W}$  gilt:

- Erwartungswert

$$E(\hat{\beta}^{\mathbf{W}}) = (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} E(\mathbf{Y}) = (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} \mathbf{X} \beta = \beta,$$

d.h.  $\hat{\beta}^{\mathbf{W}}$  ist erwartungstreu,

- Kovarianz

$$\begin{aligned} \text{Cov}(\hat{\beta}^{\mathbf{W}}) &= (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} \text{Cov}(\mathbf{Y}) \mathbf{W}^{-1^T} \mathbf{X} (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1^T} \\ &= \sigma^2 (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1} \mathbf{W} \mathbf{W}^{-1^T} \mathbf{X} (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1^T} \\ &= \sigma^2 (\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \end{aligned}$$

- Ist zudem  $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2\mathbf{W})$ , dann gilt  $\hat{\beta}^{\mathbf{W}} \sim N(\beta, \sigma^2(\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1})$



## Eigenschaften des Aitken-Schätzers

### Gauß-Markov-Theorem

Unter den Modell-Annahmen  $E(\mathbf{Y}) = \mathbf{X}\beta$  und  $\text{Cov}(\mathbf{Y}) = \sigma^2\mathbf{W}$  gilt, dass unter allen Schätzern  $\tilde{\beta}$  von  $\beta$ , die linear und erwartungstreu sind, d.h. für die  $\tilde{\beta} = \mathbf{A}\mathbf{Y}$  für eine  $(k \times n)$ -Matrix  $\mathbf{A}$  und  $E(\tilde{\beta}) = \beta$  gilt, der Aitken-Schätzer  $\hat{\beta}^{\mathbf{W}}$  am besten ist, d.h.  $\text{Var}(\mathbf{c}^T \hat{\beta}^{\mathbf{W}}) \leq \text{Var}(\mathbf{c}^T \tilde{\beta})$  für beliebige  $\mathbf{c} \in \mathbb{R}^k$ .  
 $\hat{\beta}^{\mathbf{W}}$  ist also BLUE.

*Bemerkung: Das Theorem folgt aus dem klassischen Gauß-Markov-Theorem für  $\mathbf{Y}^*, \mathbf{X}^*$*

## Prognosen und Residuen als Projektionen

## Schiefwinklunge Projektion

- Aus dem Aitken-Schätzer ergeben sich die Prognosen und Residuen:

$$\hat{Y}_i = \mathbf{x}_i \hat{\boldsymbol{\beta}}^{\mathbf{W}} \quad \text{und} \quad \hat{e}_i = Y_i - \mathbf{x}_i \hat{\boldsymbol{\beta}}^{\mathbf{W}}$$

- Für geometrische Betrachtung brauchen wir die quadratische Form

$$(\mathbf{u}, \mathbf{v}) \mapsto \mathbf{u}^T \mathbf{W}^{-1} \mathbf{v} = \langle \mathbf{u}, \mathbf{v} \rangle_{\mathbf{W}}$$

- Alternativer Orthogonalitätsbegriff:

$$\mathbf{u} \perp_{\mathbf{W}} \mathbf{v} \iff \langle \mathbf{u}, \mathbf{v} \rangle_{\mathbf{W}} = \mathbf{u}^T \mathbf{W}^{-1} \mathbf{v} = 0 \iff \mathbf{W}^{-1/2} \mathbf{u} \perp \mathbf{W}^{-1/2} \mathbf{v},$$

- Alternativer Längenbegriff

$$\|\mathbf{u}\|_{\mathbf{W}}^2 = \langle \mathbf{u}, \mathbf{u} \rangle_{\mathbf{W}} = \mathbf{u}^T \mathbf{W}^{-1} \mathbf{u}$$

## Schiefwinklunge Projektion

- Auch für den alternativen Längenbegriff gilt der Satz des Pythagoras. Das heißt, gilt  $\mathbf{a} \perp_{\mathbf{w}} \mathbf{b}$  für  $\mathbf{a}, \mathbf{b} \in \mathbb{R}^n$  so ist

$$\|\mathbf{a} + \mathbf{b}\|_{\mathbf{w}}^2 = \|\mathbf{a}\|_{\mathbf{w}}^2 + \|\mathbf{b}\|_{\mathbf{w}}^2$$

- $\mathbf{Y}$  lässt sich eindeutig als Summe eines Vektors  $\mathbf{Y}^{\mathbf{w}} \in \mathcal{M}$  und eines Vektors  $\hat{\mathbf{e}}^{\mathbf{w}} \in \mathcal{M}_{\mathbf{w}}^{\perp} = \{\tilde{\mathbf{e}} \in \mathbb{R}^n : \langle \tilde{\mathbf{e}}, \tilde{\mu} \rangle_{\mathbf{w}} = 0 \text{ für alle } \tilde{\mu} \in \mathcal{M}\}$  zerlegen, d.h.

$$\mathbf{Y} = \hat{\mathbf{Y}}^{\mathbf{w}} \oplus_{\mathbf{w}} \hat{\mathbf{e}}^{\mathbf{w}}.$$

- Man kann zeigen, dass diese identisch zu den Prognosen und Residuen aus dem Aitken-Schätzer sind

## Schiefwinklunge Projektion

- $\hat{\mathbf{Y}}$  und  $\hat{\mathbf{e}}$  können nun wieder über eine Projektionsmatrix gewonnen werden:

$$\hat{\mathbf{Y}} = \mathbb{H}\mathbf{Y} \text{ mit der Projektionsmatrix } \mathbb{H} = \mathbf{P}_{\mathcal{M}}^{\mathbf{W}} = \mathbf{X}(\mathbf{X}^T \mathbf{W}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}^{-1}$$

- Es gilt wieder  $\hat{\mathbf{e}} = \mathbf{Y} - \mathbb{H}\mathbf{Y} = (\mathbf{I} - \mathbb{H})\mathbf{Y} = (\mathbf{I} - \mathbb{H})\boldsymbol{\varepsilon}$ .
- Es ist leicht nachzuprüfen, dass  $\mathbb{H}\mathbb{H} = \mathbb{H}$  und damit  $(\mathbf{I} - \mathbb{H})\mathbb{H} = 0$  sowie  $(\mathbf{I} - \mathbb{H})(\mathbf{I} - \mathbb{H}) = \mathbf{I} - \mathbb{H}$ .
- Die Matrizen  $\mathbb{H}$  und  $\mathbf{I} - \mathbb{H}$  sind also beide Projektionsmatrizen;  $\mathbb{H}$  projiziert auf  $\mathcal{M}$  und  $\mathbf{I} - \mathbb{H}$  auf  $\mathcal{M}_{\mathbf{W}}^{\perp}$ .
- Das heißt  $\tilde{\boldsymbol{\mu}} = \mathbb{H}\mathbf{Y}$  ist das Element in  $\mathcal{M}$  mit kleinstem Abstand  $\|\tilde{\boldsymbol{\mu}} - \mathbf{Y}\|_{\mathbf{W}}^2$  zu  $\mathbf{Y}$

## Statistische Eigenschaften der Prognosen und Residuen

- $\hat{\mathbf{Y}}$  ist erwartungstreu:

$$E(\hat{\mathbf{Y}}) = E(\mathbb{H}\mathbf{Y}) = \mathbb{H}E(\mathbf{Y}) = \mathbf{X}(\mathbf{X}^T\mathbf{W}^{-1}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{W}^{-1}\mathbf{X}\boldsymbol{\beta} = \mathbf{X}\boldsymbol{\beta} = \boldsymbol{\mu}$$

- Für den Erwartungswert von  $\hat{\mathbf{e}}$  gilt:

$$E(\hat{\mathbf{e}}) = E((\mathbf{I} - \mathbb{H})\mathbf{Y}) = E(\mathbf{Y} - \mathbb{H}\mathbf{Y}) = E(\mathbf{Y}) - E(\mathbb{H}\mathbf{Y}) = \boldsymbol{\mu} - \boldsymbol{\mu} = \mathbf{0}$$

- Für die Kovarianz von  $\hat{\mathbf{Y}}$  gilt:

$$\begin{aligned} \text{Cov}(\hat{\mathbf{Y}}) &= \mathbb{H}\text{Cov}(\mathbf{Y})\mathbb{H}^T = \sigma^2\mathbb{H}\mathbf{W}\mathbb{H}^T \\ &= \sigma^2[\mathbf{X}(\mathbf{X}^T\mathbf{W}^{-1}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{W}^{-1}]\mathbf{W}[\mathbf{W}^{-1}\mathbf{X}(\mathbf{X}^T\mathbf{W}^{-1}\mathbf{X})^{-1}\mathbf{X}^T] \\ &= \sigma^2\mathbf{X}(\mathbf{X}^T\mathbf{W}^{-1}\mathbf{X})^{-1}\mathbf{X}^T \\ &= \sigma^2\mathbb{H}\mathbf{W} \end{aligned}$$

## Statistische Eigenschaften der Prognosen und Residuen

- Ähnlich lässt sich zeigen, dass

$$\text{Cov}(\hat{\mathbf{e}}) = \sigma^2(\mathbf{W} - \mathbb{H}\mathbf{W}) = \sigma^2(\mathbf{I} - \mathbb{H})\mathbf{W}$$

- Für die Kovarianz zwischen  $\hat{\mathbf{Y}}$  und  $\hat{\mathbf{e}}$  lässt sich rechnen

$$\text{Cov}(\hat{\mathbf{e}}, \hat{\mathbf{Y}}) = \sigma^2(\mathbf{I} - \mathbb{H})\mathbf{W}\mathbb{H}^T = \sigma^2 \underbrace{(\mathbf{I} - \mathbb{H})\mathbb{H}}_{=0} \mathbf{W} = \mathbf{0}.$$

- $\hat{\mathbf{e}}$  und  $\hat{\mathbf{Y}}$  sind unkorreliert und damit bei normalverteiltem  $\mathbf{Y}$  stochastisch unabhängig

## Statistische Eigenschaften der Prognosen und Residuen

Ist  $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2\mathbf{W})$  so folgt:

- Für die Verteilung von  $\hat{\mathbf{Y}}$

$$\hat{\mathbf{Y}} \sim N(\mathbf{X}\beta, \sigma^2\mathbb{H}\mathbf{W}) = N(\mathbf{X}\beta, \sigma^2\mathbf{X}(\mathbf{X}^T\mathbf{W}^{-1}\mathbf{X})^{-1}\mathbf{X}^T)$$

- Für die Verteilung von  $\hat{\mathbf{e}}$

$$\hat{\mathbf{e}} \sim N(\mathbf{0}, \sigma^2(\mathbf{I} - \mathbb{H})\mathbf{W}) = N(\mathbf{0}, \sigma^2(\mathbf{W} - \mathbf{X}(\mathbf{X}^T\mathbf{W}^{-1}\mathbf{X})^{-1}\mathbf{X}^T))$$

$$\text{da } \mathbb{H} = \mathbf{X}(\mathbf{X}^T\mathbf{W}^{-1}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{W}^{-1}$$



## Schätzen der Residualvarianz

## Schätzen der Residualvarianz

- Betrachte zunächst die sogenannte Devianz

$$Dev(\mathcal{M}) = \|\mathbf{Y} - \mathbf{X}\hat{\beta}\|_{\mathbf{W}}^2 = (\mathbf{Y} - \mathbf{X}\hat{\beta})^T \mathbf{W}^{-1} (\mathbf{Y} - \mathbf{X}\hat{\beta}) = \hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}}$$

- $Dev(\mathcal{M})$  misst den Abstand zwischen  $\mathbf{Y}$  und den Prognosen  $\hat{\mathbf{Y}}$  bezüglich des alternativen Abstandbegriffs
- Man kann zeigen, dass  $Dev(\mathcal{M}) \sim \sigma^2 \chi_{n-k}^2$
- Damit gilt  $E(\hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}}) = \sigma^2(n - k)$
- Dies impliziert, dass

$$\hat{\sigma}^2 = \hat{\sigma}_{\mathbf{W}}^2 = \frac{1}{n - k} \hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}}$$

ein erwartungstreuer Schätzer für  $\sigma^2$  ist.

## Der Aitken-Schätzer als MLE

- Ist  $\mathbf{Y} \sim N(\mu, \sigma^2 \mathbf{W})$  so kann man zeigen, dass der Aitken-Schätzer  $\hat{\beta}^{\mathbf{W}}$  auch der Maximum Likelihood Schätzer von  $\beta$  ist
- Außerdem kann man zeigen, dass der MLE für die Varianz gegeben ist durch:

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \|\mathbf{Y} - \mathbf{X}\hat{\beta}^{\mathbf{W}}\|_{\mathbf{W}}^2 = \frac{1}{n} \hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}} = \frac{1}{n} \|\hat{\mathbf{e}}^{\mathbf{W}}\|_{\mathbf{W}}^2.$$

- Dieser stimmt offensichtlich nicht mit dem erwartungstreuen Schätzer  $\hat{\sigma}_{\mathbf{W}}^2$  überein

## Testen linearer Hypothesen im allgemeinen linearen Modell

## Lineare Hypothesen

- Betrachte wieder den Modellraum  $\mathcal{M} = \{\mathbf{X}\tilde{\beta} \mid \tilde{\beta} \in \mathbb{R}^k\} \subseteq \mathbb{R}^n$
- Als Nullhypothese wird nun ein linearer Teilraum  $\mathcal{M}_0 \subsetneq \mathcal{M}$  von  $\mathcal{M}$  betrachtet
- $\mathcal{M}_0$  kann z.B. durch eine  $(r \times k)$ -dimensionale Restriktionsmatrix  $\mathbf{C}$  definiert sein:  
 $\mathcal{M}_0 = \{\mathbf{X}\tilde{\beta} \mid \tilde{\beta} \in \mathbb{R}^k \text{ mit } \mathbf{C}\tilde{\beta} = 0\}$
- Bezeichnen Dimension von  $\mathcal{M}_0$  mit  $k_0$
- Suchen einen statistischen Test für

$$H_0 : \mu \in \mathcal{M}_0 \quad \text{vs.} \quad H_1 : \mu \in \mathcal{M} \setminus \mathcal{M}_0$$

bzw. im Beispiel:

$$H_0 : \mathbf{C}\beta = 0 \quad \text{vs.} \quad H_1 : \mathbf{C}\beta \neq 0$$

## Lineare Hypothesen - Beispiele

- Werden im Folgenden 2 Beispiele betrachten:
  - (a)  $\mathcal{M}_0 = \{\mathbf{X}\tilde{\beta} : \tilde{\beta}_1 \in \mathbb{R}, \tilde{\beta}_2 = \dots = \tilde{\beta}_k = 0\}$ . Das Modell  $\mu \in \mathcal{M}_0$  entspricht dem Fall, in dem keine unabhängige Variable einen Einfluss auf  $Y$  hat.
  - (b) Gegeben sei  $S \subsetneq \{2, \dots, k\}$ , z.B. die Koeffizienten aller Dummy-Variablen, die zu einem bestimmten Faktor gehören. Der Nullraum  $\mathcal{M}_0 = \{\mathbf{X}\tilde{\beta} \mid \tilde{\beta} \in \mathbb{R}^k, \tilde{\beta}_j = 0 \text{ für alle } j \in S\}$  entspricht der Situation, dass keine Dummy-Variable und damit der Faktor insgesamt keinen Einfluss auf  $Y$  hat.

## Lineare Hypothesen - Prognosen und Teststatistik

- Betrachte zunächst die Prognosen:
  - (1) für  $\mathcal{M}$ :  $\hat{\mathbf{Y}} = \mathbf{P}_{\mathcal{M}}^{\mathbf{W}} \mathbf{Y} (= \mathbb{H}_{\mathcal{M}}^{\mathbf{W}} \mathbf{Y})$ ,
  - (2) für  $\mathcal{M}_0$ :  $\hat{\mathbf{Y}}_0 = \mathbf{P}_{\mathcal{M}_0}^{\mathbf{W}} \mathbf{Y} (= \mathbb{H}_{\mathcal{M}_0}^{\mathbf{W}} \mathbf{Y})$ .
- Um einen Test für  $H_0 : \mu \in \mathcal{M}_0$  gegen  $H_1 : \mu \in \mathcal{M} \setminus \mathcal{M}_0$  zu definieren, betrachte nun die Zerlegung

$$\mathbf{Y} - \hat{\mathbf{Y}}_0 = \underbrace{\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0}_{\in \mathcal{M}} \oplus_{\mathbf{W}} \underbrace{\hat{\mathbf{e}}}_{\in \mathcal{M}_{\mathbf{W}}^{\perp}}.$$

- Damit folgt

$$\|\mathbf{Y} - \hat{\mathbf{Y}}_0\|_{\mathbf{W}}^2 = \|\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0\|_{\mathbf{W}}^2 + \|\hat{\mathbf{e}}\|_{\mathbf{W}}^2 = (\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0)^T \mathbf{W}^{-1} (\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0) + \hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}}.$$

## Lineare Hypothesen - Prognosen und Teststatistik

- Große Werte von  $\|\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0\|_{\mathbf{W}}^2$  sprechen gegen  $H_0 : \mu \in \mathcal{M}_0$  und für  $H_1 : \mu \in \mathcal{M} \setminus \mathcal{M}_0$ .
- Man kann zeigen, dass

$$\frac{1}{\sigma^2}(\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0)^T \mathbf{W}^{-1}(\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0) \underset{H_0}{\sim} \chi_{\dim(\mathcal{M}) - \dim(\mathcal{M}_0)}^2 = \chi_{k-k_0}^2$$

- Bei bekannter Residualvarianz  $\sigma^2$  liefert die Verwerfungsregel

$$\frac{1}{\sigma^2}(\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0)^T \mathbf{W}^{-1}(\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0) \geq Q_{k-k_0}^{\chi^2}(1 - \alpha)$$

also einen Niveau  $\alpha$  Test für unser Testproblem.



## Berechnung von $\hat{\mathbf{Y}}_0$ - Beispiel (a); Vereinfacht mit $\mathbf{W} = \text{diag}(w_1, \dots, w_n)$

- $\mathcal{M}_0 = \{\mathbf{X}\tilde{\beta} | \tilde{\beta}_2, \dots, \tilde{\beta}_n = 0\} = \{\tilde{\mu} = \mu_0 \mathbf{1} | \mu_0 \in \mathbb{R}\}$
- Unter  $\mathcal{M}_0$  sind alle Erwartungswerte  $E(\mathbf{Y}_i)$  gleich:  $E(\mathbf{Y}_1) = \dots = E(\mathbf{Y}_n)$ .
- Der gewichtete KQ-Schätzer ist

$$\hat{\mu}_0 = \operatorname{argmin}_{\mu_0 \in \mathbb{R}} \sum_{i=1}^n (Y_i - \mu_0)^2 v_i \quad \text{mit} \quad v_i = 1/w_i.$$

- Man kann leicht zeigen, dass

$$\hat{\mu}_0 = \sum_{i=1}^n Y_i v_i / \sum_{i=1}^n v_i$$

das gewichtete arithmetische Mittel ist

- Schließlich ist also  $\hat{\mathbf{Y}}_0 = \hat{\mu}_0 \mathbf{1}$ .

## Berechnung von $\hat{\mathbf{Y}}_0$ - Beispiel (b)

- $\mathcal{M}_0 = \{\mathbf{X}\tilde{\boldsymbol{\beta}} \mid \tilde{\beta}_j = 0 \text{ für } j \in S\}, S \subsetneq \{1, \dots, k\}.$
- Bilden die Matrix  $\mathbf{X}_0$  durch Löschung der Spalten  $\mathbf{x}_j, j \in S$ , und definieren  $s = |S|$
- Damit ist

$$\hat{\mathbf{Y}}_0 = \underbrace{\mathbf{X}_0}_{n \times (k-s)} \underbrace{(\mathbf{X}_0^T \mathbf{W}^{-1} \mathbf{X}_0)^{-1}}_{(k-s) \times (k-s)} \underbrace{\mathbf{X}_0^T \mathbf{W}^{-1} \mathbf{Y}}_{(k-s) \times n}$$

der Aitken-Schätzer ohne die Kovariablen in  $S$ .

## F-Test für lineare Hypothesen

- Ist  $\sigma^2$  unbekannt, so wird es geschätzt
- Wir wissen bereits, dass

$$(n - k) \frac{\hat{\sigma}_{\mathbf{W}}^2}{\sigma^2} = \frac{1}{\sigma^2} \|\hat{\mathbf{e}}\|_{\mathbf{W}}^2 = \frac{1}{\sigma^2} \hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}} \sim \chi_{n-k}^2$$

- $\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0$  und  $\hat{\mathbf{e}}$  sind unkorreliert und damit unter der Annahme  $\mathbf{Y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{W})$  stochastisch unabhängig
- Damit folgt

$$F = \frac{(\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0)^T \mathbf{W}^{-1} (\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0) / (k - k_0)}{\hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}} / (n - k)} \sim F_{k-k_0, n-k},$$

wobei  $F_{k-k_0, n-k}$  die F-Verteilung mit den Freiheitsgraden  $df_1 = k - k_0$  und  $df_2 = n - k$  ist

## F-Test für lineare Hypothesen

- $H_0$  kann damit unter Kontrolle des Fehlers 1. Art auf dem Signifikanzniveau  $\alpha$  verworfen werden mit der Verwerfungsregel

$$F \geq Q_{k-k_0, n-k}^F(1 - \alpha).$$

- Die Entscheidung kann äquivalent über einen p-Wert getroffen werden:

$$p = 1 - F_{k-k_0, n-k}^F(F) \leq \alpha .$$

## Alternative Darstellung der F-Statistik für lineare Hypothesen

- Es gilt

$$||\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_0||_{\mathbf{W}}^2 = ||\hat{\mathbf{e}}_0||_{\mathbf{W}}^2 - ||\hat{\mathbf{e}}||_{\mathbf{W}}^2 = \hat{\mathbf{e}}_0^T \mathbf{W}^{-1} \hat{\mathbf{e}}_0 - \hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}}$$

wobei  $\hat{\mathbf{e}}_0 = \mathbf{Y} - \hat{\mathbf{Y}}_0$  das Residuum des Nullmodels  $\mathcal{M}_0$  ist

- Wir erhalten somit

$$F = \frac{(\hat{\mathbf{e}}_0^T \mathbf{W}^{-1} \hat{\mathbf{e}}_0 - \hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}}) / (k - k_0)}{\hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}} / (n - k)}.$$

- Man nennt den allgemeinen  $F$ -Test auch *Devianz-Analyse*, da  $\hat{\mathbf{e}}_0^T \mathbf{W}^{-1} \hat{\mathbf{e}}_0 = ||\hat{\mathbf{e}}_0||^2 = ||\mathbf{Y} - \hat{\mathbf{Y}}_0^{\mathbf{W}}||^2$  und  $\hat{\mathbf{e}}^T \mathbf{W}^{-1} \hat{\mathbf{e}} = ||\hat{\mathbf{e}}||^2 = ||\mathbf{Y} - \hat{\mathbf{Y}}^{\mathbf{W}}||^2$  die *Devianzen* von  $\mathcal{M}$  und  $\mathcal{M}_0$  sind

## Modelle mit autokorrelierten Fehlern

## Allgemeines Setup

- Beobachtungen  $Y_1, Y_2, \dots, Y_n$  seien nun zeitlich geordnete Messungen einer einzigen Beobachtungseinheit
- Da sie der selben Beobachtungseinheit entstammen, sind  $Y_1, Y_2, \dots, Y_n$  in der Regel korreliert
- Wenn  $Y_i = \mathbf{x}_i\beta + \epsilon_i$ , dann ist davon auszugehen, dass die Störterme  $\epsilon_1, \dots, \epsilon_n$  korreliert sind
- Werden im Folgenden verschiedene Modelle für die Kovarianzstruktur der  $\epsilon_i$  betrachten

## Das AR(1)-Modell für die Störterme

- Im AR(1)-Modell nimmt man an, dass für  $\rho \in (-1, 1)$  und  $\sigma^2 > 0$

$$\text{Cov}(\epsilon) = \frac{\sigma^2}{1 - \rho^2} \begin{pmatrix} 1 & \rho & \rho^2 & \dots & \rho^{n-1} \\ \rho & 1 & \rho & \dots & \rho^{n-2} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \rho^{n-1} & \rho^{n-2} & \rho^{n-3} & \dots & 1 \end{pmatrix}$$

- Korrelation kann auch durch die sogen. *Autokorrelationsfunktion* beschrieben werden:

### Autokorrelationsfunktion

$$\text{ACF}(j) = \text{Cov}(\epsilon_i, \epsilon_{i-j}) = \frac{\text{Cov}(\epsilon_i, \epsilon_{i-j})}{\text{Var}(\epsilon_i)}$$



## Autokorrelationsfunktion

### Autokorrelationsfunktion

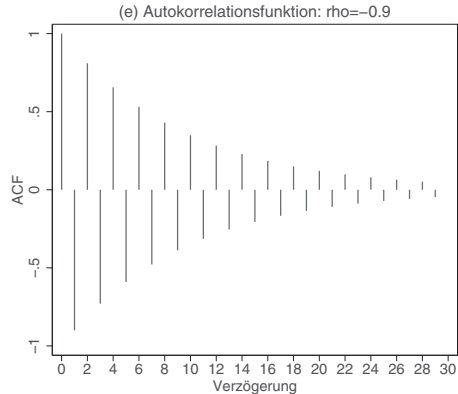
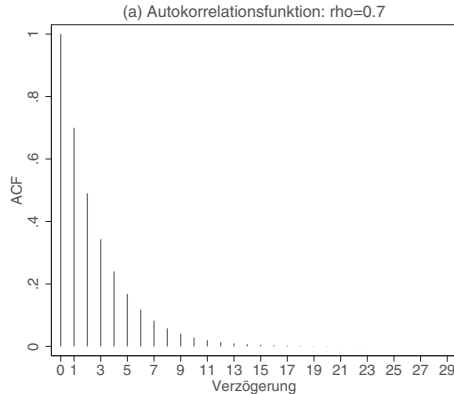
$$\text{ACF}(j) = \text{Cov}(\epsilon_i, \epsilon_{i-j}) = \frac{\text{Cov}(\epsilon_i, \epsilon_{i-j})}{\text{Var}(\epsilon_i)}$$

- Die Autokorrelationsfunktion beschreibt die Korrelation zweier Beobachtungen  $Y_i$  und  $Y_{i-j}$  in Abhängigkeit von ihrem zeitlichen Abstand  $j$
- Im AR(1)-Modell fällt sie mit dem zeitlichen Abstand  $j$  ab und es gilt:

$$\text{ACF}(j) = \rho^j$$

- Falls  $\rho > 0$  fällt die Korrelation geometrisch, für  $\rho < 0$  hat man einen alternierenden Abfall (siehe nächste Folie)

## Autokorrelationsfunktion im AR(1) Modell



Autokorrelationsfunktion bei AR(1)-Korrelation für  $\rho = 0.7$  bzw.  $\rho = -0.9$ ; aus Fahrmeir, Kneib und Lang (2009)

## Stochastisches Modell des AR(1) Modells

- Die Kovarianzstruktur des AR(1)-Modells kann über unendliche Folge von stochastisch unabhängigen Zufallsvariablen erzeugt werden
- Es seien

$$U_n, U_{n-1}, U_{n-2}, \dots, U_1, U_0, U_{-1}, U_{-2}, \dots$$

stochastisch unabhängig mit  $E(U_i) = 0$  und  $\text{Var}(U_i) = \sigma^2$  für alle  $i$ .

- Die AR(1)-korrelierten Störterme  $\epsilon_i$  können dann durch die folgenden unendlichen Summen erzeugt werden:

$$\epsilon_i = \sum_{k=0}^{\infty} \rho^k U_{i-k}$$

## Stochastisches Modell des AR(1) Modells

- Man kann zeigen, dass dann

$$\epsilon_i = \rho\epsilon_{i-1} + U_i$$

- $\epsilon_{i-1} = \sum_{k=0}^{\infty} \rho^k U_{i-1-k}$  und  $U_i$  sind stoch. unabh.
- $\epsilon_i$  erfüllt das lineare Modell mit  $\epsilon_{i-1}$  als unabhängige Variable
- Sprechen daher von *Autokorrelation der Ordnung 1*, abgekürzt *AR(1)*
- Ordnung 1, da  $\epsilon_i$  nur vom letzten  $\epsilon_j$  abhängt

## Autokorrelation höherer Ordnung

- Man spricht von Autokorrelation der Ordnung  $j$  für ein  $j > 1$  und schreibt  $AR(j)$ , wenn

$$\epsilon_i = \alpha_1 \epsilon_{i-1} + \alpha_2 \epsilon_{i-2} + \dots + \alpha_j \epsilon_{i-j} + U_i,$$

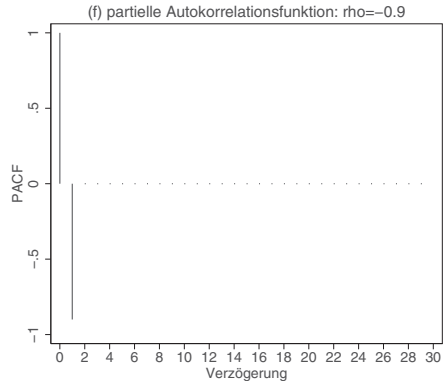
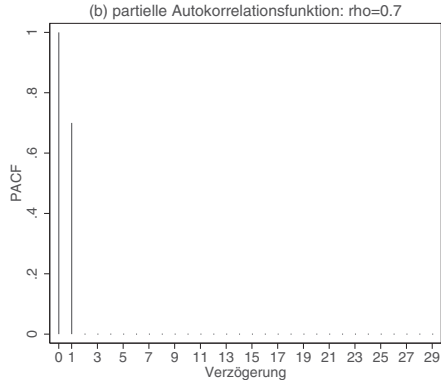
mit  $E(U_i) = 0$ ,  $Var(U_i) = \sigma^2$ , stochastisch unabhängig von  $\epsilon_1, \dots, \epsilon_{i-1}$

- Man betrachtet die sogenannte partielle Autokorrelationsfunktion:

$$j \mapsto PACF(j) = \alpha_j$$

- Liefert Regressionskoeffizienten von  $\epsilon_{i-j}$  des lin. Modells für  $\epsilon_i$  mit Kovariablen  $\epsilon_{i-1}, \dots, \epsilon_{i-j}$ .

## PACF im AR(1) Modell



PACF des AR(1)-Modells mit  $\rho = 0.7$  bzw.  $\rho = -0.9$ ; aus Fahrmeier, Kneib und Lang (2009)

## Diagnose in Daten

## Empirische ACF und PACF

- Um anhand von Daten zu prüfen werden die empirische Autokorrelationsfunktion

$$\widehat{ACF}(j) = \frac{\widehat{Cov}(\epsilon_i, \epsilon_{i-j})}{\widehat{Var}(\epsilon_i)},$$

wobei  $\widehat{Cov}(\epsilon_i, \epsilon_{i-j}) = \frac{1}{n} \sum_{i=j+1}^n \hat{\epsilon}_i \hat{\epsilon}_{i-j}$ ,

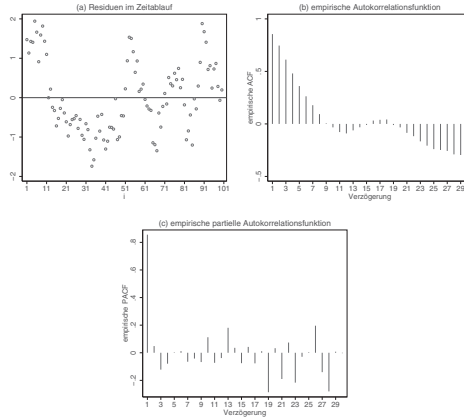
- und die empirische partielle Autokorrelationsfunktion

$$\widehat{PACF}(j) = \hat{\alpha}_j,$$

wobei  $\hat{\alpha}_j$  KQ-Schätzer einer lin. Regression von  $\hat{\epsilon}_i$  nach  $\hat{\epsilon}_{i-1}, \dots, \hat{\epsilon}_{i-j}$  ist, betrachtet



## Beispiel: AR(1) Modell



Aus Fahrmeier, Kneib und Lang (2009)

## Schätzung der Parameter

## Setup

- Bisher Annahme, dass **W** bekannt ist und nur  $\sigma^2$  und  $\beta$  geschätzt werden müssen
- Nun auch **W** unbekannt
- Benötigen Annahmen um die Zahl der Parameter bei der Schätzung von **W** zu reduzieren
- Hier: Schätzmethoden im AR(1)-Modell (dann muss nur  $\rho$  geschätzt werden um **W** zu bestimmen)

## Zweistufige Schätzung

1. Schätzer  $\hat{\beta}$  als (klassischen) KQ-Schätzer und bestimme zugehörige Residuen  $\hat{e}$
2. Schätze die Autokorrelation  $\rho$

$$\hat{\rho} = \frac{\sum_{i=2}^n \hat{e}_i \hat{e}_{i-1}}{\sqrt{\sum_{i=2}^n \hat{e}_i^2} \sqrt{\sum_{i=2}^n \hat{e}_{i-1}^2}}.$$

3. Bilde die Gewichtsmatrix

$$\hat{\mathbf{W}} = \frac{1}{1 - \hat{\rho}^2} \begin{pmatrix} 1 & \hat{\rho} & \hat{\rho}^2 & \dots & \hat{\rho}^{n-1} \\ \hat{\rho} & 1 & \hat{\rho} & \dots & \hat{\rho}^{n-2} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \hat{\rho}^{n-1} & \hat{\rho}^{n-2} & \hat{\rho}^{n-3} & \dots & 1 \end{pmatrix},$$

und schätze  $\beta$  mit dem Aitken-Schätzer mit  $\mathbf{W} = \hat{\mathbf{W}}$ .

## Zweistufige Schätzung

- Schritte 1.-3. können zur Verbesserung der Anpassung iteriert werden
- Man nennt dies die *Prais-Winston-Schätzung*
- Unter recht allgemeinen Bedingungen: die Schätzung ist konsistent

## Maximum-Likelihood-Methode

- Unter der Normalverteilungsannahme für  $\mathbf{Y}$  ist die log-Likelihood der Daten gegeben als:

$$l(\beta, \sigma, \rho) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) + \frac{1}{2}(1 - \rho^2) - \frac{1}{2}(\mathbf{Y} - \mathbf{X}\beta)^T \mathbf{W}^{-1}(\mathbf{Y} - \mathbf{X}\beta) / \sigma^2$$

- Maximiere durch nullsetzen des Scores (Ableitung der log-Likelihood)
- Numerische Lösung des resultierenden Gleichungssystems